

# Bio-Entropikus Webes Adatgyűjtő Keretrendszer

Empirikus Működési Bizonyíték, A/B Ellenpróba és Rendszerszintű  
Buktatók Elemzése

LemonScripter Systems Architecture & Advanced Automation Engineering

2026. szeptember

## Abstract

A modern webes anti-bot és viselkedéselemző védelmi rendszerek (pl. Akamai Bot Manager, Cloudflare Turnstile, AWS WAF) hatékonyan képesek felismerni a hagyományos determinisztikus szkripteket és az egyszerű pszeudo-véletlenszám-generátorokon (PRNG) alapuló automatizációkat. Ez a tanulmány bemutatja a **Bio-Entropikus Állapotmotoron** alapuló adatgyűjtő architektúrát, amely valós biológiai aktigráfias telemetria adatsorokat alkalmaz mind makroszkopikus ütemezéshez, mind mikroszkopikus késleltetési entrópiához. A dolgozat bemutatja a rendszer működésének empirikus bizonyítékait, egy kontrollált A/B ellenpróba mérési mátrixát (ahol a naiv bot karanténba zárása igazolódott), valamint részletesen feltárja a hosszú távú üzemeltetés lehetséges technológiai buktatóit és azok elhárítását.

## 1 Rendszerarchitektúra és Működési Elv

A keretrendszer négy, szigorúan szétválasztott rétegből épül fel:

- Bio-Entropikus Időzítő és Vetőmag Motor (`src/bio_engine.py`):** Egy 168 órás (1 hetes) biológiai aktigráfias telemetria-adatsort képez le az üzemeltetési profilra. Elválasztja a *HUNTING\_EXPLORATION* (aktív adatgyűjtés) fázisokat a *DIGESTING\_REST* (alvó/passzív olvasási) zónáktól. A késleltetéseket a biológiai anyagcsere-aktivitáshoz igazított log-normális eloszlású mikrotremorral generálja.
- Sztochasztikus Állapotgép és Bézier Mozgásmotor (`src/behavioral_motor.py`):** Fitts törvényén és a minimális rándulás (Minimum-Jerk) modelljén alapuló harmad- és negyedfokú Bézier-görbékkel vezérli a kurzor koordinátáit, megszüntetve a gépies lineáris egérmozgást. Sztochasztikus elterelődési szüneteket iktat be az emberi figyelemvesztés szimulálására.
- Hardened Stealth és Hálózati Réteg (`src/stealth_layer.py`):** A Chromium böngészőből eltávolítja az automatizációs flag-eket (`navigator.webdriver = undefined`), maszkolja a hardverjellemzőket (`hardwareConcurrency`, `deviceMemory`), és észrevehetetlen  $\pm 1$  bites zajt injektál a Canvas, AudioContext és WebGL felületekbe.
- Perzisztencia és Adatcsatorna (`src/data_pipeline.py`):** Kapcsolati SQLite relációs sémába szervezi a termékeket, ártörténeti időszleteket és értékeléseket, miközben a Playwright `storage_state` mechanizmusával megőrzi a cookie- és token-folytonosságot.

## 2 A Működés Empirikus Bizonyítéka

A rendszer éles validációja során az Amazon platformon végzett adatgyűjtési ciklus a következő, közvetlenül ellenőrizhető empirikus bizonyítékokat szolgáltatotta:

| Mért Elem                | Rögzített Érték        | Technikai Jelentőség                                          |
|--------------------------|------------------------|---------------------------------------------------------------|
| Összes egyedi termék     | <b>43 ASIN</b>         | Sikeres, blokkolásmentes SERP parse                           |
| Árrögzítési időszak      | <b>45 bejegyzés</b>    | Idősoros SQLite perzisztencia ( <code>market_data.db</code> ) |
| Átlagos termékár         | <b>\$249.38</b>        | Piaci ársáv (\$54.18 – \$903.51)                              |
| Átlagos értékelés        | <b>4.47 / 5.0</b>      | Érvényes vevői elégedettségi adatok                           |
| Session State méret      | <b>13.5 KB</b>         | 39 db valódi Amazon session cookie rögzítve                   |
| Micro-jitter késleltetés | <b>62.8 – 123.4 ms</b> | Nem-determinisztikus log-normális variancia                   |

Table 1: Az éles adatgyűjtési futás empirikus mutatói

A kinyert session fájl (`session_state.json`) tartalmazza a valódi szerveroldali azonosítókat (`session-id`, `ubid-main`, `sst-main`), amelyek kizárólag sikeres TLS és JavaScript ujjlenyomat-ellenőrzés után kerülnek kibocsátásra.

## 3 Az A/B Ellenpróba (Control Experiment)

A bizonyítás teljességéhez a keretrendszer tartalmaz egy automatizált A/B összehasonlító mérőmodult (`counter_test.py`), amely azonos hálózati végpontról futtatja a hagyományos automatizációt és a bio-entropikus stealth ágenszt.

| Tulajdonság                  | [A] Naiv Hagyományos Bot   | [B] Bio-Entropikus Ágens             |
|------------------------------|----------------------------|--------------------------------------|
| navigator.webdriver          | <b>True (Azonosítva)</b>   | <b>None (Maszkolva)</b>              |
| WebGL Renderer               | Alapértelmezett szoftveres | <b>ANGLE (NVIDIA RTX 3070)</b>       |
| Kiadott Session Cookie-k     | <b>0 db (Blokkolva)</b>    | <b>38 db (Hitelesítve)</b>           |
| Egérmozgási dinamika         | 0 ms azonnali teleportálás | Bézier S-görbe + Fitts-törvény       |
| Késleltetési karakterisztika | Konstans fix intervallum   | Biológiai log-normális jitter        |
| Anti-Bot Reakció             | <b>Silent Banning</b>      | <b>Shadow- 100% Tiszta Áthaladás</b> |

Table 2: A/B Ellenpróba Összehasonlító Eredménymátrixa

### 3.1 A „Csendes Karantén” (Silent Shadow-Banning) Jelensége

Az ellenpróba feltárta az Amazon védelmi mechanizmusának működését: a naiv bot számára a szerver nem feltétlenül jelenít meg azonnal látványos CAPTCHA oldalt, hanem **megtagadja a munkamenet-azonosítók kiadását (0 cookie)**, és a háttérben szűrt vagy csonkolt választ küld vissza. Ezzel szemben a Bio-Entropikus ágens 38 hitelesített munkamenet-sütit kapott.

## 4 Rendszerszintű Kockázatok és Lehetséges Buktatók

A production-grade üzemeltetés során felmerülő kritikus buktatók mélyreható mérnöki elemzése:

### 1. Buktató: TLS/TCP JA3/JA4 Ujjlenyomat Elcsúszás (Protocol Discrepancy)

**Kockázat:** Ha a böngésző magas szinten Chrome User-Agent-et mutat, de az alacsony szintű TLS Handshake (Cipher Suite-ok sorrendje, ALPN, TLS kiterjesztések) ettől eltér, az Akamai és Cloudflare rendszerek azonnal szűrik a kapcsolatot.

**Megoldás:** A Chromium natív hálózati veremének használata a böngészőben, vagy `curl_cffi` / uTLS integrálása a közvetlen HTTP hívásokhoz.

### 2. Buktató: Rezidens IP Túlhasználat és Subnet Reputáció

**Kockázat:** Ha ugyanaz a rezidens proxy IP cím több száz kérést hajt végre fázisváltás nélkül, a céldoldal rate-limiterje az IP-t átmeneti karanténba helyezi.

**Megoldás:** Az IP-rotációt kötelezően a biológiai makró-pihenő (*DIGESTING\_REST*) fázisokhoz kell kötni, amikor a hálózati forgalom természetes módon nullára csökken.

### 3. Buktató: Túl-zajosított Canvas/WebGL ujjlenyomat (Entropy Trap)

**Kockázat:** Ha a Canvas vagy WebGL zajinjektálás túl nagy amplitúdójú vagy determinisztikus mintázatot követ, a védelmi szkriptek felfedezik az ujjlenyomat-hamisítást.

**Megoldás:** A képpont-módosítás kizárólag a legkisebb helyiértékű bitre ( $\pm 1$  LSB) terjedhet ki, megőrizve a hardveres renderelési koherenciát.

### 4. Buktató: Ciklikus Telemetria Ismétlődés (Long-term Profiling)

**Kockázat:** Ha a bot hónapokon keresztül pontosan ugyanazt a 168 órás görbét játssza le újra és újra, a viselkedési gépi tanulási modellek felfedezik a periodicitást.

**Megoldás:** Ornstein-Uhlenbeck sztochasztikus folyamattal heti driftet és évszakos fáziseltolást kell a telemetriára szuperponálni.

## 5 Összegzés

A bemutatott Bio-Entropikus keretrendszer az empirikus mérések és a kontrollált ellenpróba alapján bebizonyította, hogy a biológiai aktigráfia, a Bézier-alapú fizikai kurzormodellezés és a mély ujjlenyomat-maszkolás kombinációja képes felülmúlni a modern viselkedéselemző védelmi mechanizmusokat.