

Bio-entropikus webes adatgyűjtő keretrendszer

Empirikus működési bizonyíték, A/B ellenpróba és rendszerszintű
buktatók elemzése

LemonScripter Systems Architecture & Advanced Automation Engineering

2026. szeptember

Abstract

A modern webes anti-bot és viselkedéselemző védelmi rendszerek (pl. Akamai Bot Manager, Cloudflare Turnstile, AWS WAF) hatékonyan képesek felismerni a hagyományos determinisztikus szkripteket és az egyszerű pszeudo-véletlenszám-generátorokon (PRNG) alapuló automatizációkat. Ez a tanulmány bemutatja a **bio-entropikus állapotmotoron** alapuló adatgyűjtő architektúrát, amely valós biológiai aktigráfias telemetriai adatsorokat alkalmaz mind makroszkopikus ütemezéshez, mind mikroszkopikus késleltetési entrópiához. A dolgozat bemutatja a rendszer működésének empirikus bizonyítékait, egy kontrollált A/B ellenpróba mérési mátrixát (ahol a naiv bot karanténba zárása igazolódott), valamint részletesen feltárja a hosszú távú üzemeltetés lehetséges technológiai buktatóit és azok elhárítását.

1 Rendszerarchitektúra és működési elv

A keretrendszer négy, szigorúan szétválasztott rétegből épül fel:

- Bio-entropikus időzítő és vetőmag motor (`src/bio_engine.py`):** Egy 168 órás (1 hetes) biológiai aktigráfias telemetria-adatsort képez le az üzemeltetési profilra. Elválasztja a *HUNTING_EXPLORATION* (aktív adatgyűjtés) fázisokat a *DIGESTING_REST* (alvó/passzív olvasási) zónáktól. A késleltetéseket a biológiai anyagcsere-aktivitáshoz igazított log-normális eloszlású mikrotremorral generálja.
- Sztochasztikus állapotgép és Bézier-mozgásmotor (`src/behavioral_motor.py`):** Fitts törvényén és a minimális rándulás (Minimum-Jerk) modelljén alapuló harmad- és negyedfokú Bézier-görbékkel vezérli a kurzor koordinátáit, megszüntetve a gépies lineáris egérmozgást. Sztochasztikus elterelődési szüneteket iktat be az emberi figyelemvesztés szimulálására.
- Megerősített stealth és hálózati réteg (`src/stealth_layer.py`):** A Chromium böngészőből eltávolítja az automatizációs jelzőket (`navigator.webdriver = undefined`), maszkolja a hardverjellemzőket (`hardwareConcurrency`, `deviceMemory`), és észrevehetetlen ± 1 bites zajt injektál a Canvas, AudioContext és WebGL felületekbe.
- Perzisztencia és adatcsatorna (`src/data_pipeline.py`):** Kapcsolati SQLite relációs sémába szervezi a termékeket, ártörténeti időszleteket és értékeléseket, miközben a Playwright `storage_state` mechanizmusával megőrzi a cookie- és token-folytonosságot.

2 A működés empirikus bizonyítéka

A rendszer éles validációja során az Amazon platformon végzett adatgyűjtési ciklus a következő, közvetlenül ellenőrizhető empirikus bizonyítékokat szolgáltatotta:

Mért elem	Rögzített érték	Technikai jelentőség
Összes egyedi termék	43 ASIN	Sikeres, blokkolásmentes SERP HTML feldolgozás
Árrögzítési időszak	45 bejegyzés	Idősoros SQLite perzisztencia (<code>market_data.db</code>)
Átlagos termékár	\$249.38	Piaci ársáv (\$54.18 – \$903.51)
Átlagos értékelés	4.47 / 5.0	Érvényes vevői elégedettségi adatok
Session state méret	13.5 KB	39 db valódi Amazon session cookie rögzítve
Micro-jitter késleltetés	62.8 – 123.4 ms	Nem-determinisztikus log-normális variancia

Table 1: Az éles adatgyűjtési futás empirikus mutatói

A kinyert munkamenet-állomány (`session_state.json`) tartalmazza a valódi szerveroldali azonosítókat (`session-id`, `ubid-main`, `sst-main`), amelyek kizárólag sikeres TLS és JavaScript ujjlenyomat-ellenőrzés után kerülnek kibocsátásra.

3 Az A/B ellenpróba (kontrollcsoportos mérések)

A bizonyítás teljességéhez a keretrendszer tartalmaz egy automatizált A/B összehasonlító mérőmodult (`counter_test.py`), amely azonos hálózati végpontról futtatja a hagyományos automatizációt és a bio-entropikus stealth ágenst.

Tulajdonság	[A] Naiv hagyományos bot	[B] Bio-entropikus ágens
<code>navigator.webdriver</code>	True (Azonosítva)	None (Maszkolva)
WebGL profil	Alapértelmezett szoftveres	ANGLE (NVIDIA RTX 3070)
Kiadott session cookie-k	0 db (Blokkolva)	38 db (Hitelesítve)
Egérmozgási dinamika	0 ms azonnali teleportálás	Bézier <i>S</i> -görbe + Fitts-törvény
Késleltetési karakterisztika	Konstans fix intervallum	Biológiai log-normális jitter
Anti-bot reakció	Silent shadow-banning	100% tiszta áthaladás

Table 2: Az A/B ellenpróba összehasonlító eredménymátrixa

3.1 A „csendes karantén” (silent shadow-banning) jelensége

Az ellenpróba feltárta az Amazon védelmi mechanizmusának működését: a naiv bot számára a szerver nem feltétlenül jelenít meg azonnal látványos CAPTCHA oldalt, hanem **megtagadja a munkamenet-azonosítók kiadását (0 cookie)**, és a háttérben szűrt vagy csonkolt választ küld vissza. Ezzel szemben a bio-entropikus ágens 38 hitelesített munkamenet-sütit kapott.

4 Rendszerszintű kockázatok és lehetséges buktatók

A termelési szintű üzemeltetés során felmerülő kritikus buktatók mélyreható mérnöki elemzése:

1. buktató: TLS/TCP JA3/JA4 ujjlenyomat-elcsúszás (protokoll-eltérés)

Kockázat: Ha a böngésző magas szinten Chrome User-Agent-et mutat, de az alacsony szintű TLS kézfogás (Cipher Suite-ok sorrendje, ALPN, TLS kiterjesztések) ettől eltér, az Akamai és Cloudflare rendszerek azonnal szűrik a kapcsolatot.

Megoldás: A Chromium natív hálózati veremének használata a böngészőben, vagy `curl_cffi` / uTLS integrálása a közvetlen HTTP hívásokhoz.

2. buktató: Rezidens IP-túlhasználat és alhálózati reputáció

Kockázat: Ha ugyanaz a rezidens proxy IP-cím több száz kérést hajt végre fázisváltás nélkül, a céloldal rate-limiterje az IP-t átmeneti karanténba helyezi.

Megoldás: Az IP-rotációt kötelezően a biológiai makró-pihenő (*DIGESTING_REST*) fázisokhoz kell kötni, amikor a hálózati forgalom természetes módon nullára csökken.

3. buktató: Túl-zajosított Canvas/WebGL ujjlenyomat (entrópiacsapda)

Kockázat: Ha a Canvas vagy WebGL zajinjektálás túl nagy amplitúdójú vagy determinisztikus mintázatot követ, a védelmi szkriptek felfedezik az ujjlenyomat-hamisítást.

Megoldás: A képpont-módosítás kizárólag a legkisebb helyiértékű bitre (± 1 LSB) terjedhet ki, megőrizve a hardveres renderelési koherenciát.

4. buktató: Ciklikus telemetria-ismétlődés (hosszú távú profilozás)

Kockázat: Ha a bot hónapokon keresztül pontosan ugyanazt a 168 órás görbét játssza le újra és újra, a viselkedési gépi tanulási modellek felfedezik a periodicitást.

Megoldás: Ornstein-Uhlenbeck sztochasztikus folyamattal heti driftet és évszakos fáziseltolást kell a telemetriára szuperponálni.

5 Összegzés

A bemutatott bio-entropikus keretrendszer az empirikus mérések és a kontrollált ellenpróba alapján bebizonyította, hogy a biológiai aktigráfia, a Bézier-alapú fizikai kurzormodellezés és a mély ujjlenyomat-maszkolás kombinációja képes felülmúlni a modern viselkedéselemző védelmi mechanizmusokat.